

INSTITUTO TECNOLÓGICO DE ESTUDIOS SUPERIORES
DE MONTERREY — CAMPUS GUADALAJARA

ESCUELA DE INGENIERÍAS Y CIENCIAS

Artículo 3: Clasificador Naïve Bayes

Materia: Análisis de métodos de razonamiento e
incertidumbre (Gpo 101)

Autores:

Tamara Hernández Romero

A01735955

Oscar Yael Baltazar

A01278421

Jun Kee Lee

A01643044

Daniela Fernanda Velderrain

A00227755

14 de septiembre de 2026

Índice

1. Introducción	1
2. Metodología y Aplicación	2
2.1. Descripción del conjunto de datos	2
2.2. Preprocesamiento y limpieza de datos	3
2.3. Construcción y ajuste del modelo Naïve Bayes	3
2.4. Evaluación del modelo	4
3. Resultados	4
3.1. Desempeño del Modelo	4
3.2. Limitaciones del modelo	5
3.3. Interpretación	5
4. Conclusiones	5
5. Referencias	7
6. Apéndice	7

Resumen

Los modelos financieros tradicionales suelen basarse en datos numéricos estructurados, dejando de lado información cualitativa clave contenida en noticias financieras sobre eventos como cambios directivos, demandas o lanzamientos estratégicos. Con el fin de evaluar el valor predictivo de esta información no estructurada, se implementó un modelo de Clasificación Naïve Bayes en R para categorizar el nivel de impacto de las noticias sobre los índices bursátiles (Alto frente a Otro/Bajo) utilizando únicamente sus titulares. Se procesó un conjunto de 3,024 titulares mediante técnicas de procesamiento de lenguaje natural (NLP) con el paquete `tidytext`, aplicando tokenización, eliminación *stop words* y la creación de una matriz dispersa de frecuencias bajo el enfoque de bolsa de palabras (*bag-of-words*). La evaluación del modelo, entrenado con una partición 70/30 y suavizado de Laplace, reveló un desempeño sumamente limitado: una exactitud del 50.7 %, una precisión del 33.3 %, una sensibilidad del 54.5 % y un puntaje F1 del 41 %, con un total de 300 falsos positivos y 125 falsos negativos. Estos resultados demuestran que el texto crudo de los titulares resulta insuficiente para tomar decisiones de inversión confiables, pues la baja precisión y la presencia de falsos negativos representan un costo de riesgo inaceptable en el ámbito financiero.

1. Introducción

Los mercados financieros reaccionan de forma casi inmediata a la información disponible y una parte considerable de esa información llega en forma de texto no estructurado, como: titulares de noticias que reportan eventos corporativos, cambios regulatorios, choques macroeconómicos o movimientos de los principales índices bursátiles. Diversos estudios han mostrado que el análisis textual de noticias financieras puede aportar valor predictivo sobre el comportamiento del mercado, más allá de lo que capturan únicamente los datos numéricos estructurados (Schumaker & Chen, 2009). Sin embargo extraer esa señal de manera sistemática requiere transformar texto libre en una representación numérica que un modelo estadístico pueda procesar, típicamente mediante técnicas de procesamiento de lenguaje natural (NLP, por sus siglas en inglés).

En este trabajo se aborda el problema de clasificar el nivel de impacto esperado de una noticia financiera (Alto frente a Otro/Bajo) utilizando únicamente el texto de su titular, para ello se empleó un clasificador Naïve Bayes, un método probabilístico ampliamente utilizado en tareas de clasificación de texto por su simplicidad compu-

tacional y su razonable desempeño incluso bajo el supuesto, rara vez cierto en la práctica, de independencia condicional entre las palabras que componen un documento. El conjunto de datos utilizado, *Wall Street Pulse*, contiene 3,024 titulares de noticias financieras publicadas entre febrero y agosto de 2025, acompañados de variables estructuradas como el sentimiento reportado, el sector afectado, el tipo de evento de mercado y el índice bursátil asociado; el texto de los titulares se procesó mediante tokenización y construcción de una matriz dispersa de frecuencias bajo el enfoque de *bag-of-words*, utilizando el paquete `tidytext` de R.

El resto de este documento se organiza de la siguiente manera, la sección de Metodología y Aplicación describe el conjunto de datos, el proceso de limpieza y la “tokenización” del texto, la construcción de la matriz documento-término, y el procedimiento de entrenamiento y evaluación del clasificador, la sección de Resultados presenta las métricas de desempeño del modelo (exactitud, precisión, sensibilidad, puntaje F1 y matriz de confusión) junto con su interpretación en el contexto de la toma de decisiones financieras, particularmente el costo relativo de los falsos positivos frente a los falsos negativos para un inversionista; finalmente, la sección de Conclusiones resume los hallazgos principales y discute las limitaciones del enfoque basado únicamente en texto crudo.

2. Metodología y Aplicación

2.1. Descripción del conjunto de datos

Se utilizó un conjunto de 3,024 registros de noticias financieras, cada uno compuesto por un titular (*Headline*) y variables asociadas: fecha de publicación, fuente, tipo de evento de mercado (*Market_Event*), índice bursátil relacionado (*Market_Index*), cambio porcentual del índice, volumen de operación, sentimiento de la noticia (*Sentiment*), sector afectado (*Sector*), compañía relacionada y, como variable objetivo, el nivel de impacto esperado (*Impact_Level*), codificado originalmente en tres categorías: *High*, *Medium* y *Low*, con una distribución relativamente balanceada entre ellas (965, 1,039 y 1,020 observaciones).

Para simplificar el problema de clasificación y evitar la ambigüedad semántica entre categorías intermedias, la variable objetivo se recodificó en dos niveles mediante la función `case_when()` de `dplyr`: *Alto* (antes *High*) y *Otro/Bajo* (que agrupa *Medium* y *Low*). Esta produjo una proporción de 31.9% de noticias de impacto Alto frente a 68.1% de Otro/Bajo, lo cual introduce un desbalance moderado.

2.2. Preprocesamiento y limpieza de datos

El texto de los titulares se procesó siguiendo un enfoque de *bag-of-words* mediante el paquete `tidytext`:

1. **Tokenización.** Cada titular se descompuso en palabras individuales (tokens) utilizando `unnest_tokens()`, generando una tabla en formato *tidy* con un token por renglón, asociado a su documento (`doc_id`) y su clase de impacto.
2. **Remoción de palabras vacías (*stop words*).** Se eliminaron las palabras funcionales sin contenido semántico relevante mediante un `anti_join()` contra el léxico integrado `stop_words` de `tidytext`.
3. **Filtrado de tokens numéricos.** Se removieron los tokens compuestos exclusivamente por dígitos mediante una expresión regular, ya que no aportan información léxica generalizable.
4. **Construcción de la matriz de frecuencias.** Se calculó la frecuencia de cada palabra por documento (`count(doc_id, word)`) y se construyó una matriz dispersa documento–término con la función `cast_sparse()`, donde cada renglón representa un titular y cada columna una palabra del vocabulario retenido.

El vector de etiquetas (`impact_class`) se alineó con los documentos que sobrevivieron el proceso de tokenización y filtrado, descartando aquellos titulares que quedaron vacíos de contenido léxico tras la limpieza (por ejemplo, titulares faltantes o compuestos únicamente por *stop words*). Finalmente, la matriz documento–término y su vector de etiquetas se dividieron en conjuntos de entrenamiento (70 %) y prueba (30 %) utilizando `createDataPartition()`, que garantiza un muestreo aleatorio estratificado respecto a la variable objetivo.

2.3. Construcción y ajuste del modelo Naïve Bayes

Se entrenó un clasificador Naïve Bayes utilizando la función `naive_bayes()`, tomando como predictores las frecuencias de palabras de la matriz documento–término y como variable respuesta la clase de impacto binaria. El modelo asume independencia condicional entre las palabras dado el nivel de impacto y estima la probabilidad de cada clase mediante el teorema de Bayes:

$$P(C_k | \mathbf{w}) \propto P(C_k) \prod_{i=1}^n P(w_i | C_k) \quad (1)$$

donde C_k representa la clase de impacto y w_i cada término. Se aplicó suavizado de Laplace ($\alpha = 1$) para evitar probabilidades nulas en palabras no observadas.

2.4. Evaluación del modelo

El desempeño del modelo se evaluó sobre el conjunto de prueba mediante una matriz de confusión, tomando como clase positiva *Alto*. A partir de ella se calcularon las siguientes métricas: exactitud (*Accuracy*), precisión (*Precision / Pos Pred Value*), sensibilidad (*Recall / Sensitivity*) y puntaje F1 (media armónica entre precisión y sensibilidad).

3. Resultados

3.1. Desempeño del Modelo

Al aplicar el pipeline descrito sobre el conjunto de noticias financieras, el modelo obtuvo el siguiente desempeño sobre el conjunto de prueba:

Cuadro 1: Métricas de desempeño del clasificador Naïve Bayes sobre el conjunto de prueba.

Métrica	Valor
Exactitud (Accuracy)	50.7 %
Precisión (Precision)	33.3 %
Sensibilidad (Recall)	54.5 %
Puntaje F1	41.0 %
Falsos positivos	300
Falsos negativos	125

La precisión de 33.3% indica que, de cada tres noticias que el modelo clasificó como de impacto *Alto*, únicamente una lo era realmente, generando un volumen considerable de falsos positivos (300 casos). La sensibilidad de 54.5%, si bien es mayor que la precisión, sigue implicando que prácticamente la mitad de las noticias de impacto real *Alto* no fueron detectadas por el modelo, materializándose en 125

falsos negativos. El puntaje F1 de 41 % confirma un balance pobre entre ambas métricas.

3.2. Limitaciones del modelo

Esta limitación es consistente con las características del enfoque utilizado: una representación de *bag-of-words* basada en frecuencias absolutas de palabras, sin ponderación por relevancia (como *TF-IDF*), sin considerar el orden o contexto de las palabras (*n-gramas*), y sin incorporar las variables estructuradas disponibles en el conjunto de datos (sentimiento, sector, cambio porcentual del índice, volumen de operación), que podrían aportar señal adicional no capturada por el texto por sí solo. Además, el supuesto de independencia condicional entre palabras es una simplificación fuerte para el lenguaje natural, donde el significado de una noticia financiera frecuentemente depende de combinaciones de términos (por ejemplo, “recorte” junto con “tasas” frente a “recorte” junto con “personal”).

3.3. Interpretación

Un falso positivo lleva a un inversionista a realizar compras, ventas o rebalanceos de portafolio innecesarios; ya que si esto tiene un costo en rentabilidad, suele ser una pérdida pequeña y transitoria. Por otra parte, un falso negativo implica que una noticia de alto impacto pase inadvertida, lo que puede traducirse en la omisión de órdenes de contención de pérdidas (*stop-loss*) y, en consecuencia, en pérdidas directas de capital o costos de oportunidad significativamente mayores. Bajo este criterio, el desempeño actual del modelo en sensibilidad (54.5 %) resulta algo preocupante, pues implica que casi la mitad de los eventos verdaderamente relevantes no estarían siendo señalados a tiempo.

4. Conclusiones

El presente trabajo implementó un clasificador Naïve Bayes para categorizar el nivel de impacto de noticias financieras (Alto frente a Otro/Bajo) utilizando únicamente el texto de sus titulares, procesado mediante tokenización y una representación de bolsa de palabras (*bag-of-words*), arroja que los resultados obtenidos (una exactitud de apenas 50.7 %, una precisión de 33.3 %, una sensibilidad de 54.5 % y un puntaje

F1 de 41 %), indican que el texto crudo del titular, por sí solo, aporta una señal predictiva muy limitada sobre el nivel de impacto real de una noticia en el mercado.

Un patrón relevante en los resultados es que el modelo cometió más del doble de falsos positivos (300) que de falsos negativos (125), lo cual sugiere una tendencia del clasificador a sobreestimar la clase de Impacto Alto: genera un número considerable de falsas alarmas en relación con los aciertos reales, lo que explica la baja precisión observada a pesar de una sensibilidad moderada. Esto es consistente con una limitación conocida de Naïve Bayes: el supuesto de independencia condicional entre palabras rara vez se cumple en el lenguaje financiero, donde el significado de una frase suele depender de combinaciones de palabras (por ejemplo, “recorte de tasas” frente a “alza de tasas”) que un modelo de palabras individuales no puede distinguir.

Es importante reconocer una limitación metodológica central de este trabajo, pues si bien el planteamiento original sugería incorporar, además de la presencia/frecuencia de palabras, otros factores relevantes disponibles en el conjunto de datos (como el sentimiento reportado, el sector afectado, el tipo de evento de mercado o el volumen de operación), el modelo aquí presentado se entrenó exclusivamente sobre la matriz de texto, que si bien es plausible que buena parte del poder predictivo real sobre el impacto de una noticia resida en estas variables estructuradas más que en la elección léxica del titular, y su ausencia probablemente explica una parte considerable del bajo desempeño observado.

Estos hallazgos tienen una implicación práctica directa para el contexto financiero: dado que un falso negativo (pasar por alto una noticia de impacto real) representa un riesgo considerablemente más costoso para un inversionista que un falso positivo, un modelo con una precisión tan baja como la aquí obtenida no es apto para la toma de decisiones de inversión sin supervisión humana adicional, incluso si su sensibilidad resultara aceptable.

Como trabajo futuro, sería valioso extender este modelo incorporando las variables estructuradas disponibles en el conjunto de datos junto con la representación textual, explorar esquemas de ponderación como TF-IDF en lugar de conteos crudos de frecuencia, incluir n-gramas que capturen combinaciones de palabras con significado financiero específico, y comparar el desempeño de Naïve Bayes contra otros clasificadores (por ejemplo, regresión logística o máquinas de vectores de soporte) que no dependan del supuesto de independencia condicional entre términos.

5. Referencias

Schumaker, R. P., & Chen, H. (2009). Textual analysis of stock market prediction using breaking financial news: The AZFin text system. *ACM Transactions on Information Systems*, 27(2), Article 12.

6. Apéndice

- [Repositorio de Github](#)